基于知识图谱、事理图谱、与推荐相关论文keypoint

笔记本:	snowcement的笔记本		
创建时间:	2018/10/16 15:12	**更新时间:**	2018/11/26 14:42
作者:	snowcement@126.com		
标签:	知识图谱		

知识图谱相关:

---

1 干货 | 大规模知识图谱的构建、推理及应用

- https://mp.weixin.qq.com/s?__biz=MjM5MDI3MjA5MQ==&mid=2697266451&idx=1&sn=264e01bf70c410ee5cee9b3d95a08a15&chksm=8376fa27b401733198c913c9a2be6a6622394a58864d698bc57e
- 构建: 将众多的实体和关系需要从原始数据（可以是结构化也可以是非结构化）中被抽取出来，并以图的方式进行结构化存储
  - 结构化数据：很容易转换为图结构
  - 非结构化数据构建方法:
    - NLP
    - DL:
      1. 可用于抽取AVP(属性-值对)
      2. 端到端的NER:
         - 从一段**非结构化文本**中找出相关实体（triplet中的主词和宾词），并标注出其位置以及类型
         - 是 NLP领域中一些复杂任务（如关系抽取、信息检索等）的基础
         - 实现技术:
           - 早期基于字典和规则的方法
           - 传统ML的方法:
             - NER:**一个序列标注问题**， 不同于分类问题，序列标注问题中的预测标签不仅与输入特征有关，还与之前的预测标签有关，也就是预测标签之间存在相互依赖和影响
             - HMM
             - MEMM
             - CRF： 条件随机场（Conditional Random Field，CRF）是序列标注的主流模型。它的目标函数不仅考虑输入的状态特征函数，还包含了标签转移特征函数。在训练的时候可以使用SGD学习参数。在预测时，可以使用Vertibi算法求解使目标函数最大化的最优序列
           - DL:
             - BiLSTM-CNN-CRF： 主要由Embedding层（词向量、字向量等）、BiLSTM、tanh隐藏层以及CRF层组成（对于中文可以不需要CNN）
             - CNN-CRF
             - RNN-CRF： 实验表明**BiLSTM-CRF**可以获得较好的效果， 在特征方面，由于秉承了深度学习的优点，所以无需特征工作的铺垫，使用词向量及字向量就可以得到不错的效果
             - Attention机制:
               - BiLSTM-CRF+Attention机制，将原来的字向量和词向量的拼接改进为按权重求和，使用两个隐藏层来学习Attention的权值，这样使得模型可以动态地利用词向量和字向量的信息。同时加入NE种类的特征，并在字向量上使用Attention来学习关注更有效的字符。实验效果优于BiLSTM-CRF的方法
             - 仅需少量标注样本的半监督来进行相应的工作
               - https://www.cnblogs.com/robert-dlut/p/6847401.html
      3. 关系抽取：**一个序列标注问题，采用模型与NER相同**
      4. 关系补全:
         - 通过现有知识图谱来预测实体之间的关系，是对关系抽取的重要补充
         - 传统方法:
           - TransE和TransH: 假设实体和关系处于**相同的语义空间**，把关系作为从实体A到实体B的翻译来建立实体和关系嵌入
           - 一个实体是由多种属性组成的综合体，不同关系关注实体的不同属性，所以仅仅在一个空间内对他们进行建模是不够的
         - TransR:
           - 将实体和关系**投影**到不同的空间中，在实体空间和关系空间构建实体和关系嵌入
           - 特定的关系投影能够使得两个实体在这个关系下真实地靠近彼此，使得不具有此关系的实体彼此远离
      5. 知识融合，
         - 包含以下几部分:
           - 实体对齐
           - 属性对齐
           - 冲突消解
           - 规范化等
         - 对开放域很难，对**特定领域** 可以通过别名举证、领域知识等方法进行对齐和消解，从技术角度来看，这里会涉及较多的逻辑，所以偏传统机器学习方法，甚至利用业务逻辑即可覆盖大部分场景
  - **没有统一的方法**，因为其构建需要一整套知识工程的方法， 知识的更新也是不可避免的，所以一定要重视快速迭代和快速产出检验
- 查询:
  - RDF->OWL->SPARQL
  - postgresql
- 存储:
  - 选**关系数据库**还是**NoSQL 数据库**（内存数据库、图数据库）？ 要不要用**内存数据库**（e.g.redis）？ 要不要用**图数据库**（Neo4J、graphsql、sparkgraphx（包含图计算引擎）、OrientDB、基于hbase的Titan、BlazeGraph等）？ 这些都需要根据数据场景慎重选择
    - nosql和传统关系型数据库的区别
      - 优点： 灵活的数据模型，结构比后者更丰富、 更易扩展、 高可用，查询效率高，传统关系型数据库受限于磁盘io，所以在高并发的情况下，压力倍增，而像redis这种内存数据库每秒支持10w次读写、 nosql成本也比较低
      - 缺点： 不支持sql这样的工业标准查询（学习成本高）、 大多数nosql都不支持事务、 nosql只能保证数据相对一致性，尤其是在数据同步的时候，主从服务器的状态是不一致的
    - **MySQL、MongoDB、Redis 数据库之间的区别**https://blog.csdn.net/CatStarXcode/article/details/79513425
  - **CN-DBpedia** 实际上是基于 mongo 数据库，参与开发的谢晨昊提到，一般只有**在基于特定领域才可能会用到图数据库**，就知识图谱而言，基于 json(bson) 的 mongo 就足够了。用到图查询的领域如征信，一般是需要要找两个公司之间的关联交易，会用到最短路径/社区计算等
- 知识图谱的推理， 将知识图谱表示为张量tensor形式，通过张量分解（tensor factorization）来实现对未知事实的判定:
  - 用途:
    - 链接预测（判断两个实体之间是否存在某种特定关系）
    - 实体分类（判断实体所属语义类别）
    - 实体解析（识别并合并指代同一实体的不同名称）
  - 模型:

        - RESCAL模型
        - TRESCAL模型
        - 路由排序算法（PRA算法） 常用来判断两个实体之间可能存在的关系
- 知识图谱的应用： **搜索、问答、推荐系统**、反欺诈、不一致性验证、异常分析、客户管理等。以上场景在应用中出现越来越多的**深度学习模型**
    - 知识图谱在深度学习模型中的应用， 利用大量先验知识，来大大降低模型对大规模标注语料的依赖
        - 将知识图谱的语义信息输入到深度学习模型中，将离散化的知识表示为连续化的向量， 使得知识图谱的先验知识能够称为深度学习的输入**[见Knowledge Graph Embedding相关文章]**
        - 利用知识作为优化目标的约束，指导深度学习模型的学习过程，通常是将知识图谱中的知识表示为**优化目标的后验正则项**
        - **知识图谱的表示学习**用于学习实体和关系的向量化表示，其关键是合理定义知识图谱中关于事实（三元组h,r,t）的**损失函数fr(h,t)**，其总和是三元组的两个实体h和t的向量化表示。通常情况下，当事实h,r,t成立时，期望最小化fr(h,t)，实现模型：
            - 基于距离的模型: SE模型： 当两个实体属于同一个三元组时，它们的向量表示在投影后的空间中也应该彼此靠近。损失函数定义为向量投影后的距离
            - 基于翻译的模型：TransE,TransH,TransR， 通过向量空间的向量翻译来描述实体与关系之间的相关性

---

2 知识图谱，知乎专栏

- https://zhuanlan.zhihu.com/p/31864048
- KG前身1：语义网络(Semantic Network)【与语义网（Semantic Web）是两个概念】：
    - 语义网络由相互连接的节点和边组成
        - 节点表示概念或者对象
        - 边表示他们之间的关系(**is-a关系**，比如：猫是一种哺乳动物；**part-of关系**，比如：脊椎是哺乳动物的一部分)
    - 优点：
        - 容易理解和展示。
        - 相关概念容易聚类
    - 缺点：
        - 节点和边的值没有标准，完全是由用户自己定义。————>**KG中提出RDF,解决该问题**
        - 多源数据融合比较困难，因为没有标准。————>**KG中提出RDF,解决该问题**
        - 无法区分概念节点和对象节点 ————> **RDF无法解决**， 它对具体事物的描述，缺乏抽象能力，无法对同一个类别的事物进行定义和描述。**W3C制定的另外两个标准RDFS/OWL解决了这个问题**
            - 即定义Class和Object(也称作Entity，Instance)
                - e.g. 熊是哺乳动物的一个实例： is-a关系
                - e.g. 熊是哺乳动物的一个子类： subClassOf关系
        - 无法对节点和边的标签(label，我理解是schema层，后面会介绍)进行定义————> **W3C制定的另外两个标准RDFS/OWL解决了这个问题**
    - 基于语义网络的思想建立的知名项目：
        - WordNet： 一个英语的词汇库
        - BabelNet：相对于WordNet，BabelNet是一个多语言的词汇库
        - HowNet：即知网，中文语义词典
- KG前身2：语义网（Semantic Web）

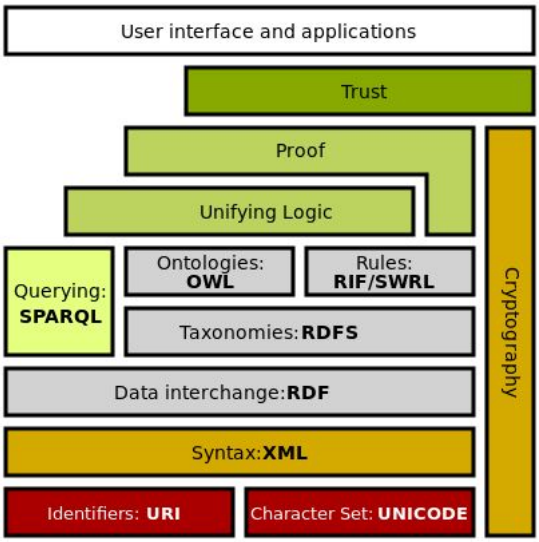

    - 技术栈【指W3C制定的用于描述和关联万维网数据的一系列技术标准】：
    - **语义网的三大核心技术： RDF，OWL和SPARQL**。RDF，RDFS/OWL属于语义网技术栈，它们的提出，使得语义网克服了语义网络的缺点。 https://zhuanlan.zhihu.com/p/32122644
        - **RDF(Resource Description Framework)，即资源描述框架**，是W3C制定的，用于描述实体/资源的标准数据模型。
            - RDF图中一共有三种类型，International Resource Identifiers(IRIs)，blank nodes 和 literals:
                - IRI我们可以看做是URI或者URL的泛化和推广，它在整个网络或者图中唯一定义了一个实体/资源，和我们的身份证号类似。
                - literal是字面量，可以把它看做是带有数据类型的纯文本，比如，罗纳尔多原名可以表示为"Ronaldo Luís Nazário de Lima"^^xsd:string。
                - blank node简单来说就是没有IRI和literal的资源，或者说匿名资源。
                - SPO每个部分的类型约束：
                    - Subject可以是IRI或blank node。
                    - Predicate是IRI。
                    - Object三种类型都可以。
            - RDF对is-a关系进行了定义，即，rdf:type
            - 如何存储、传送RDF数据【序列化方法】：
                - RDF/XML： 用XML的格式来表示RDF数据； 对于RDF来说，XML的格式太冗长，也不便于阅读，通常不会使用这种方式来处理RDF数据
                - N-Triples： 用多个三元组来表示RDF数据集，是最直观的表示方法。 开放领域知识图谱DBpedia通常是用这种格式来发布数据的
                - **Turtle**：
                    - 使用得最多的一种RDF序列化方式。它比RDF/XML紧凑，且可读性比N-Triples好
                    - 会加上前缀（Prefix）对RDF的IRI进行缩写
                    - 同一个实体拥有多个属性（数据属性）或关系（对象属性），可以只用一个subject来表示，使其更紧凑， 将一个实体用一个句子表示（这里的句子指的是一个英文句号 “.” ）而不是多个句子，属性间用分号隔开
                - RDFa： 是HTML5的一个扩展，在不改变任何显示效果的情况下，让网站构建者能够在页面中标记实体，像人物、地点、时间、评论等等。也就是说，将RDF数据嵌入到网页中，搜索引擎能够更好的解析非结构化页面，获取一些有用的结构化信息
                - JSON-LD：即 “JSON for Linking Data” ，用键值对的方式来存储RDF数据

        - **RDFS【 Resource Description Framework Schema】和OWL【 Web Ontology Language】** 进行schema层的建模:
            - 模式语言/本体语言（schema/ontology language）解决了RDF表达能力有限的困境，**是用来描述RDF数据的，在概念、抽象层面对RDF数据进行定义**
            - RDFS/OWL本质上是一些预定义词汇（vocabulary）构成的集合，用于对RDF进行类似的类定义及其属性的定义
            - 在表现形式上，它们就是RDF。其常用的方式主要是RDF/XML，Turtle
            - RDFS:
                - RDFS本质上是RDF词汇的一个扩展，当中不区分数据属性和对象属性，词汇rdf:Property定义了属性，即RDF的“边”。常用词汇如下：
                    - rdfs:Class. 用于定义类。
                    - rdfs:domain. 用于表示该属性属于哪个类别。
                    - rdfs:range. 用于描述该属性的取值类型。
                    - rdfs:subClassOf. 用于描述该类的父类。比如，我们可以定义一个运动员类，声明该类是人的子类。
                    - rdfs:subProperty. 用于描述该属性的父属性。比如，我们可以定义一个名称属性，声明中文名称和全名是名称的子类。
                    - 其实rdf:Property和rdf:type也是RDFS的词汇，因为RDFS本质上就是RDF词汇的一个扩展。在这里不罗列进去，是避免混淆
            - OWL:
                - 主要功能：
                    - 提供快速、灵活的数据建模能力。
                    - 高效的自动推理。
                        - 基于本体的推理
                        - 基于规则的推理
                - owl区分数据属性和对象属性（对象属性表示实体和实体之间的关系）：
                    - 词汇owl:DatatypeProperty定义了数据属性，
                    - 词汇owl:ObjectProperty定义了对象属性。
                - 常用词汇：
                    - 描述属性特征的词汇
                        - owl:TransitiveProperty. 表示该属性具有传递性质
                        - owl:SymmetricProperty. 表示该属性具有对称性
                        - owl:FunctionalProperty. 表示该属性取值的唯一性
                        - owl:inverseOf. 定义某个属性的相反关系
                    - 本体映射词汇（Ontology Mapping）： 用于融合多个独立的Ontology（Schema）
                        - owl:equivalentClass. 表示某个类和另一个类是相同的
                        - owl:equivalentProperty. 表示某个属性和另一个属性是相同的
                        - owl:sameAs. 表示两个实体是同一个实体
        - **SPARQL(SPARQL Protocol and RDF Query Language)**，有两部分组成：
            - 协议： 通过HTTP协议在客户端和SPARQL服务器（SPARQL endpoint）之间传输查询和结果，这也是和其他查询语言最大的区别
            - 查询语言：基于图匹配的思想。把上述的查询与RDF图进行匹配，找到符合该匹配模式的所有子图，最后得到变量的值，分为以下三步：
                - 构建查询图模式，表现形式就是带有变量的RDF。
                - 匹配，匹配到符合指定图模式的子图。
                - 绑定，将结果绑定到查询图模式对应的变量上。
- KG前身3：链接数据（Linked Data）：
    - 被当做是语义网技术一个更简洁，简单的描述。
    - 当它指语义网技术时，它更强调“Web”，弱化了“Semantic”的部分。
    - 对应到语义网技术栈，它倾向于使用RDF和SPARQL（RDF查询语言）技术，对于Schema层的技术，RDFS或者OWL，则很少使用。
    - 链接数据应该是最接近知识图谱的一个概念，从某种角度说，知识图谱是对链接数据这个概念的进一步包装
        - Linked Data更强调不同RDF数据集（知识图谱）的相互链接
        - KG不一定要链接到外部的知识图谱，更强调有一个本体层来定义实体的类型和实体之间的关系。另外，知识图谱数据质量要求比较高且容易访问，能够提供面向终端用户的信息服务（查询、问答等等）
- 知识图谱：
    - 由本体（Ontology）作为Schema层，和RDF数据模型兼容的结构化数据集
        - **本体建模，**
            - 构建方式：
                - 自顶向下：常用于领域知识图谱的本体构建
                - 自底向上：常用于开放域知识图谱的本体构建
    - 由一些相互连接的实体和他们的属性构成的。由一条条知识组成，每条知识表示为一个SPO三元组(Subject-Predicate-Object)
    - 关系也称为属性（Property）
        - 根据是实体和实体之间的关系还是实体和数据值之间的关系分为:
            - 对象属性（Object Property）
            - 数据属性（Data Property）
    - 在知识图谱中，用RDF形式化地表示这种三元关系，数据来源：
        - 结构化数据：
            - RDB2RDF标准：
                - 直接映射,**缺点**【 不能把数据库的数据映射到我们自己定义的本体上】：
                    - 数据库的表作为本体中的类（Class）
                    - 表的列作为属性（Property）
                    - 表的行作为实例/资源
                    - 表的单元格值为字面量
                    - 如果单元格所在的列是外键，那么其值为IRI，或者说实体/资源
                - R2RML【 可以让用户更灵活的编辑和设置映射规则】：
                    -
        - 半结构化数据：数据有一定的组织形式，但较结构化数据而言更松散（属性名和属性值具有多样性，比如“生日”就有“出生日期”、“诞辰”等多种表达方式），例如百度百科、维基百科、互动百科等
        - 非结构化的数据：纯文本数据

---

3 Ontop:

- http://ontop.inf.unibz.it/
- http://wenda.chinahadoop.cn/question/10246
    - Ontop和D2RQ都可以把关系数据库转为虚拟RDF数据，二者区别?
        - D2RQ基本上就不推荐了：
            - 一方面他的mapping的表达能力和文档有一些不清晰的地方，相比R2RML的文档（W3C推荐的映射语言）清晰很多，且表达能力更强
            - D2RQ翻译SPARQL2SQL的过程缺乏query optimization，在大数据情况下性能比较差，经常会出现timeout或OOM（内存消耗比较严重的情况）
            - 此外，他不支持推理。虽然D2RQ可以将KG映射到Jena Model上，通过Jena Reasoner在其上做各种inference，但是效率可想而知。而Ontop是支持推理的（backward chaining）
- 怎样使ontop把关系数据库和图数据库中的数据联合映射成一个virtualRDFgraph以便用SPARQL统一查询?
    - 关系数据库的用ontop的Mapping映射为virtual RDF，然后用RDF4J等通过SPARQL federation来管理这个映射的virtual RDF和原本的RDF数据即可。

---

4 从知识图谱到事理图谱（Event Evolutionary Graph）

- https://blog.csdn.net/tgqdt3ggamdkhaslzv/article/details/78557548
- 通过知识图谱，可以支持用户按主题而不是按字符串检索，从而真正地实现在语义层面上进行信息检索
- 事理图谱概念的提出：
  - 知识库普遍是以“概念及概念间的关系”为核心的，缺乏对“事理逻辑”知识的挖掘

	事理图谱	知识图谱
研究对象	谓词性事件及其关系	名词性实体及其关系
组织形式	有向图	有向图
主要知识形式	事理逻辑关系，以及概率转移信息	实体属性和关系
知识的确定性	事件间的演化关系多数是不确定的	多数实体关系是确定性的

  - 事理逻辑（事件之间的演化规律与模式）是一种非常有价值的常识知识
  - 事理图谱并不是以名词为核心节点的知识库，而是以事件而且是抽象类事件为核心的**事理逻辑知识库**
  - 结构上：EEG是一个有向有环图，节点代表事件，有向边表示事件间的**顺承，因果关系**（包含时间顺序），边上还标注有事件间转移概率信息
    - 事件：泛化的抽象的事件，比如，吃火锅，去机场 ，看电影
      - 太具体不行：某年某月干了什么
      - 太抽象也不行：去地方，做事情
    - 关系：只有两种：
      - 顺承关系：指两个事件在时间上先后发生的偏序关系，e.g.吃饭，买单，离开餐馆
      - 因果关系：在满足顺承关系时序约束的基础上，两个事件间有很强的因果性，强调前因后果，控制因变量影响结果
    - 拓扑结构：
      - 链状：顺承关系
      - 树状：结婚场景：
        - 买房子
        - 买汽车
        - 找照相馆
          - 拍婚纱照
        - 去旅行
          - 找旅行社
          - 订机票
      - 环状：打架报复住院，循环往复
  - 应用：
    - **事件预测**
    - **常识推理**
    - 消费意图挖掘与推荐系统
    - 对话生成
    - 问答系统
    - **辅助决策**等任务中
  - **与EEG相关研究方向**：
    - 统计脚本学习：
      - 关注事件链条的抽取，事件预测以及事件间转移概率的建模
      - e.g. 根据故事上下文推断正确的故事结尾
    - 事件间时序因果关系识别：包含时序和因果
      - 给定文本中两个事件，后者关注如何识别它们之间的时序、因果关系以及关系方向
  - 领域EEP构建步骤：
    - 数据清洗、NLP预处理、事件抽取和泛化、生成候选事件对、顺承和因果关系识别、顺承方向识别、事件转移概率计算：
- 事理图谱与知识图谱的融合

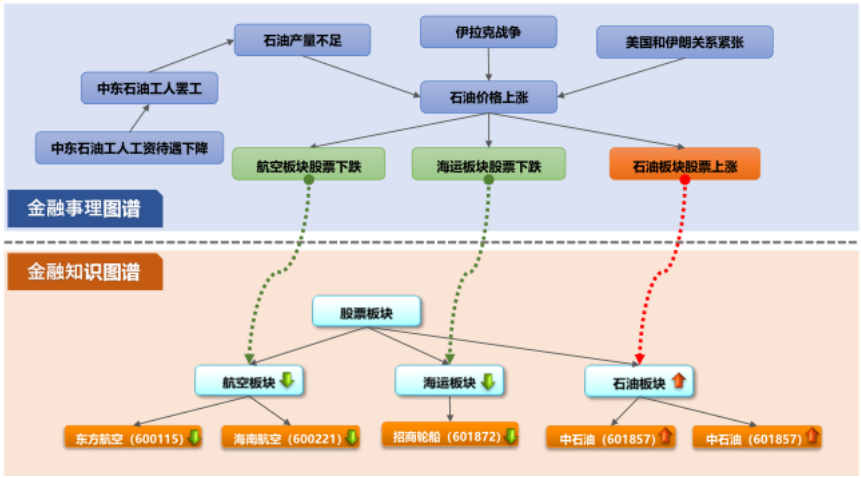

---

5 中文语义依存分析—通往中文语义理解的一条蹊径

- https://mp.weixin.qq.com/s/bvm6sISUsUEhOpTOV-NxSg
- https://www.cnblogs.com/CheeseZH/p/5768389.html
- 依存句法(Dependency Parsing, DP)：通过分析语言**单位内成分之间的依存关系**揭示其句法结构，主张句子中核心动词是支配其它成分的中心成分，而它本身却不受其它任何成分的支配，所有受支配成分都以某种依存关系从属于支配者。直观来讲，依存句法分析识别句子中的“主谓宾”、“定状补”这些语法成分，并分析各成分之间的关 系。仍然是上面的例子，其

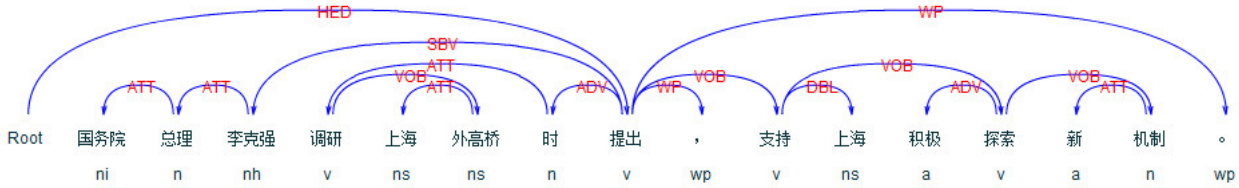

分析结果为：从分析结果中我们可以看到，句子的核心谓词为“提出”，主语是“李克强”，提出的宾语是“支持上海...”，“调研...时”是“提出”的(时间)状语，“李克强”的修饰语是“国务院总理”，“支持”的宾语是“探索 新机制”。有了上面的句法分析结果，我们就可以比较容易的看到，“提出者”是“李克强”，而不是“上海”或“外高桥”，即使它们都是名词，而且距离“提出”更近。

- 语义依存分析建立在依存理论基础上，是对语义的深层分析。可分为两个阶段，
  - 根据依存语法建立依存结构，即找出句子中的所有修饰词与核心词对，
  - 再对所有的修饰词与核心词对指定语义关系

---

6 抽象因果事理图谱的构建和应用

- https://mp.weixin.qq.com/s?__biz=MzIxMjAzNDY5Mg==&mid=2650791483&idx=1&sn=e3238c78669cf136ab05b546816e50d5&chksm=8f474bd0b830c2c6423a0ec28c645152587f5b96ffae3348a8
- 事件抽取：
  - e.g.抽象因果事理图谱构建，选取新闻语料，可以使用规则模板对**原因结果事件**抽取：
    - <Pattern, Constraint, Priority>
  - 从原因结果事件中抽取原因事件和结果事件：
    - 事件表示与采取的语料库有关，以新闻语料为例：
      - 选用动词+名词集合表示事件【包含了三元组，名词短语，动词短语等信息】
      - 如果选用三元组或者名词短语的问题：
        - 会丢失新闻中重要的主干信息
        - 会抽取到多个，需要进一步判断事件具体由哪一个表示
- 事件泛化：
  - 完成事件抽取后，事件是具体的，为了实现一类事件归一化，进而匹配成链条，需要进行泛化（同类事件归为一个事件）
    - 四川地震/熊本地震，对归为地震事件
  - 泛化后的结果表示一类事件，成为抽象事件
  - 事件抽取结果种类繁杂，如下，
    - predicate+object 总固定出现而 subject 却是动态变化的
    - subject+predicate 总是固定出现而 object 却是动态变化的
    - 存在一些更加复杂的模式
  - 泛化方法：采用高频词对的形式来具体表示抽象事件：
    - 动词：用verb net中的动词类别替换
    - 名称： 用上位词/高频同义词替换
- 事件表示学习：

---

7 事理图谱：事件演化的规律和模式

- https://mp.weixin.qq.com/s/PdnAvAh2zvXOaYGfHQGzdg
- 事理图谱中的事件用**抽象、泛化、语义完备的谓词短语**来表示，其中含有事件触发词，以及其他必需的成分来保持该事件的语义完备性。
  - 抽象和泛化指不关注事件的**具体发生时间、地点和具体施事者**，语义完备指人类能够理解该短语传达出的意义，不至于过度抽象而让人产生困惑
- 事理图谱案例：
  - 金融事理图谱：
    - 在金融领域语料上进行了探索与实践，经过多次迭代与完善，构建了一个**金融领域的事理图谱**。构建该金融事理图谱所用的语料为腾讯、网易、和讯等网站的**财经新闻文本，以及人民日报、中国青年报等多家报纸的开放领域新闻文本**。构建该图谱用到了事件抽取、因果关系抽取、相似事件识别等关键技术。目前该金融事理图谱中含有约134万事件节点（用一个短语或句子来表示事件）以及约140万的因果关系。从该图谱中随机选取1000条因果关系对进行人工评价，因果事件关系抽取准确率达到了72.5%
  - 出行领域事理图谱：
    - 基于上文相关定义，我们从互联网无结构化数据构建了一个中文出行领域事理图谱。采用的语料是知乎“旅行”话题下的32万篇用户问答对。构建过程包括事件抽取、事件间顺承和因果关系识别、事件转移概率计算等步骤。
- 有以上博文有相同内容

8 中文复合事件抽取，包括条件事件、因果事件、顺承事件、反转事件等事件抽取，并形成事理图谱

- https://java.ctolib.com/liuhuanyong-ComplexEventExtraction.html
- 基于携程游记的出行领域顺承事件图谱项目https://blog.csdn.net/lhy2014/article/details/82954146
- 特定领域因果事件图谱构建项目https://blog.csdn.net/lhy2014/article/details/82954060
- 事理图谱类型：

事件	含义	形式化	事件应用	图谱场景	举例
因果事件	某一事件导致某一事件发生	A导致B	事件预警	因果溯源 由因求果	<地震,房屋倒塌>
条件事件	某事件条件下另一事件发生	如果A那么B	事件预警	时机判定	<限制放宽, 立即增产>
反转事件	某事件与另一事件形成对立	虽然A但是B	预防不测	反面教材	<起步晚,发展快>
顺承事件	某事件紧接着另一事件发生	A接着B	事件演化	未来意图识别	<去旅游,买火车票>

- 事件的表示形式：

以因果事件为例： 已知句子：这几天非洲闹猪瘟，导致国内猪肉涨价

表示形式	含义	举例	优点	缺点
短句	以中文标点符号为分割边界形成的短句	这几天非洲闹猪瘟 &国内猪肉涨价	方便、 最原始信息	噪声多，不易融合
词序列	对短句进行分词、词性标注、 停用词形成的词序列	非洲闹猪瘟& 国内猪肉涨价	语义丰富、 较短句形式短	停用规则不易控制
短语	依存句法分析/语义角色标注， 形成主谓短语、动宾短语、主谓宾短语	非洲闹猪瘟& 猪肉涨价	语义凝固简洁	受限于依存、 语义角色性能

论文：

1 KB4Rec:ADatasetforLinkingKnowledgeBaseswith RecommenderSystems

- 构建一个开放的linked KB（knowledge base）数据集用于推荐系统(RS):knowledge-aware recommender systems
  - Freebase，将事实存储为三元组(head,relation,tail).使用的是2015年3月的版本【目前为最新发布的版本】
- RS选用三个广泛使用的数据集
  - MovieLens->movie
  - LFM-1b->music
  - Amazon book->book
- Related work for knowledge-aware recommender systems
  - 第一阶段
    - context-aware recommendation algorithms，利用社交信息【Epinions数据集】、POI属性信息【Yelp数据集】、电影属性信息【MovieLens数据集】、用户档案信息【Microblogging数据集】..
    - 利用原始RS平台的辅助信息（上下文数据）做推荐，这些数据往往辅助信息种类少，且辅助信息间关系relation patterns被忽略了
  - 第二阶段
    - HIN: ,Heterogeneous InformationNetworks，能有效学习relation patterns
    - 依赖图搜索算法，很难处理大规模关系查找
  - 第三阶段
    - KB,用于组建只是和领域事实
    - **通过连接RS items和KB entities**，但现有文献使用的均为private KB,无法获取
- 如何构建RS到KB的连接(Linkage):
  - 通过调用离线Freebase search API，用item titles作为queries,检索KB entities
  - 如果没有KB entity返回，说明RS item在linkage process被拒绝了
  - 如果至少一个KB entity返回，使用一种辅助信息作为准确连接间的一种精确的约束。e.g. IMBD ID,artist name and writer name are used for the three domains of movie, music and bookrespectively
- Linkage ratio和哪些因素可能有关?
  - KB的构建经常包含人力工作，无法忽视人类注意力的偏差
  - 流行度，成正相关，即item越流行，Linkage ratio可能越高
  - 新颖度，成负相关，即item发布时间越晚，Linkage ratio可能越低
- KB4Rec数据集的使用，选用哪些推荐算法进行试验，性能指标选取：
  - 指标：
    - MRR：mean reciprocal rank
    - HR: hit ratio
    - NDCG: normalized discounte cumulative gain
  - 推荐算法：
    - 与文献【7】相似，采用last-item recommendation task for evaluation
    - 算法：
      - BPR
      - SVDFeature
      - mCKE:第一篇文献提出利用KB和其他信息来提高推荐性能
      - KSR：Knowledge-enhanced Sequential Recommender,利用KB信息提高语义表示memory networks的性能【结果最好】
- KB4Rec数据集地址: https://github.com/RUCDM/KB4Rec#Datasets

---

2 Knowledge Graph Embedding: A Survey of Approaches and Applications【知识图谱特征学习】

- KG embedding研究的出发点：KG的表示一般基于三元组（head entity, relation, tail entity），尽管能够有效的表示结构化数据，但是底层的本质上是符号表示，使得KG很难操作; KG embedding将KG中的成分映射到一个连续的矢量空间中，不仅保留KG中的固有结构，同时简化了处理
- KG embedding研究主要分为两个阶段：
  - 阶段1：仅利用KG中的fact构建embedding, embedding只需要和每个单独fact匹配，对下游的一些任务not predictive enough
  - 阶段2：在阶段1的基础上，利用更多的信息形式，e.g.实体类型（entity type）、关系路径(relation path)、文本描述(textual description)、逻辑规则(logical rules)，得到more predictive embeddings
- 知识图谱特征学习可以：
  - 降低知识图谱的高维性和异构性；
  - 增强知识图谱应用的灵活性；
  - 减轻特征工程的工作量；
  - 减少由于引入知识图谱带来的额外计算负担
- **只基于facts的KG embedding 构建由3步组成：**
  - step1: 表示entities和relations:
    - entity表示形式：
      - 矢量
      - 考虑entity的不确定性，利用多元高斯分布对entity进行建模
    - relation常被看成在矢量空间中的操作，表示形式：
      - 矢量

        - 矩阵
        - 张量
        - 多元高斯分布
        - 混合高斯（mixtures of Gaussians）
- step2: 定义第一个打分函数
    - 每个fact(h,r,t)均对应一个score func **f_r(h, t)**，在KG中观察到的facts得分高于未观察到的，根据score function定义方式不同，这种只基于facts的KG embedding技术可被分为以下两类：
        - translational distance models：使用**基于距离的score func【目标优化函数】**，**这些模型均包含约束（e.g.强制vector embedding至少L2范数），这些约束在优化问题中被转化为正则项【正则项】**
            - TransE及其扩展，**实体/关系都是矢量空间中确定的点**
                - TransE：
                    - 简单高效，通过学习分布式的词表示来捕捉语言规律，e.g.JamesCameron + DirectorOf ≈ Avatar
                    - 处理一对多，多对一，多对多关系时有问题，e.g.一对多为例，AlfredHitchcock + DirectorOf ≈Psycho，Rebecca，RearWindow，一个导演对应多部电影，虽然这些电影属于不同实体，但是学到的矢量表示都是非常相似的，这是有问题的
                - TransE改进策略：
                    - 引入 Relation-Specific Entity Embeddings:
                        - TransH：
                            - 改进TransE：引入 **Relation-Specific Entity Embeddings**，允许实体在不同的关系中有明显不同的表示。e.g.即使Psycho，Rebecca，RearWindow在给定DirectorOf 关系时，表示很相似，但给定其他关系时，表示可能相差很大
                            - 引入relation-specific超平面，每个关系r用矢量**r**表示，在一个以**w_r**为法向量的超平面上，实体**h,t**投射到该超平面上
                        - TransR：
                            - 引入relation-specific 空间，而不是超平面；实体表示为实体空间的向量，每个关系关联到另外的关系空间，定义投影矩阵M_r（实体空间到关系空间）
                            - 每个关系都需要引入投影矩阵，不如TransE,TransH简单高效
                        - TransD:
                            - 简化TransR,比TransR更高效。将投影矩阵分解为两个矢量乘积，引入额外的映射向量**w_h，w_t, w_r**
                        - TranSparse:
                            - 简化TransR,强制投影矩阵的稀疏性
                    - relaxing translational requirement:放松**h+r≈t**的限制
                        - TransM: 每个事实（三元组）关联一个权重，通过降低一对多，多对一，多对多关系的权重，TransM允许**t**在这些关系中远离**h+r**
                        - ManifoldE: 放松约束关系，**t**约束在以**h+r**为质心，权重值为半径的超球体中
                        - TransF: 放松约束关系，**t**约束在与**h+r**为同向即可
                        - TransA: 为每个关系r引入对称非负矩阵，使用自适应Mahalanobis距离定义score
            - Gaussian Embeddings，**实体/关系被看做随机变量**
                - KG2E：将实体和关系表示成从多元高斯分布中提取的随机向量
                    - 使用 Kull-back-Leibler散度计算得分
                    - 使用概率内积计算得分
                - TransG: 实体**h,t**利用高斯分布建模，关系**r**认为可能有多重语义信息，被表示为混合高斯分布
            - 其他距离模型：
                - UM(unstructured model)
                    - TransE的简化版本，令**r** = 0
                    - 不能区分不同的关系
                - SE(structured embedding):
                    - 对每个关系r，使用两个不同的投影矩阵，分别用于head entity, tail entity
        - semantic matching models: 使用**基于相似度的score func**，通过匹配实体、关系见的潜在语义来衡量事实的合理性
            - RESCAL及其扩展
                - RESCAL:
                    - 也叫双线性模型，将实体**h,t**与一个vector关联来捕捉潜在语义，关系**r**与一个matrix关联来建模latent factors间的两两交互
                    - 其score func捕捉到了所有**h,t所有成分间**的两两交互
                - TATEC:
                    - 不仅建模了h,r,t间3者交互，还定义了h,r/t,r间2者交互
                - DisMult
                    - 简化了RESCAL，将矩阵**Mr**限制为对角阵
                    - 其score func捕捉到了**h,t**中**相同维度上成分间**的两两交互，减少了每个关系**r**所有的参数数量
                    - 模型过于简单【对角矩阵使得实体可交换】，只能处理对称关系，对于一般的KG功能不够强大
                - HolE(Holographic Embeddings)全息嵌入：
                    - 将RESCAL的表现力与DisMult的简洁高效结合
                    - 将实体、关系均表示为vector，进行Circular correlation，对pairwise interactions进行压缩，减少了每个关系**r**所有的参数数量，比RESCAL高效；且Circular correlation不能交换，可以像RESCAL一样，对非对称关系进行建模
                - ComplEx(Complex Embeddings)复数嵌入：
                    - 对DisMult的扩展，引入复数嵌入，可以更好建模非对称关系
                    - **h，r，t**不再依赖实数空间，而是依赖复数空间，非对称关系最终得到的事实会得到不同的score，这依赖相关实体对应的orders、
                    - 共轭对称施加在embeddings时，HolE被视为ComplEx的一种特殊情况
                - **ANALOGY**:
                    - 扩展RESCAL，进一步对实体、关系中相似的属性建模
                    - 已被证明DisMult、HolE、ComplEx均属于ANALOGY的一种特殊情况
            - 利用神经网络进行匹配
                - SME: Semantic Matching Energy，
                    - 在Input layer: 将fact三要素**h,r,t**映射为vector embeddings
                    - 在Hidden layer：将关系**r**与head entity **h**结合得到**g_u(h,r)**;将关系r与tail entity h结合得到**g_v(r, t)**
                    - score定义为**g_u,g_v**的点积
                    - 根据**g_u,g_v**的形式不同，SME有两个版本：
                        - SME(linear):
                        - SME(bilinear)
                - NTN: neural tensor network:
                    - 在Input layer: 将fact三要素**h,r,t**映射为vector embeddings
                    - 在Hidden layer：将h，t，和二者与特定关系张量Mr结合三者映射到一个非线性hidden layer
                - SLM:single layer model：
                    - NTN的简化形式，将h，t对应的权重矩阵，bias置零，只保留NTN中的最后一个要素
                - MLP: multi-lalyer perceptron：
                    - h，r，t均映射为单vector
                    - 在Input layer上将三者拼接，映射到非线性hidden layers
                - NAM:neural association model:（多隐层，其他都是单隐层）
                    - 在Input layer: 将fact中**h,r**映射为vector embeddings后进行拼接，经过多隐层（激活函数：Relu）和**t**生成的embeddings乘积得到score
- step3: 学习entities和relations的表示
    - 解决对所有观测facts的合理性最大化(maximize plausibility)的最优化问题
    - **模型的训练:**

        - 一些先验知识：http://www.sohu.com/a/144575100_464088
            - 封闭世界假设(Closed World Assumption, CWA)
                - 即如果我们在知识库中推不出来P或P的否定，就把P的否定加入知识库。有两种情况, CWA很有用. 一是可以**当假设知识库中的知识是完全的时候**. 例如, 在数据库中, 如果学生表中没有Peter, 则认为Peter不是学生. 二是当知道知识库的知识是不完全的, 如不足于回答一些问题, 但我们**必须在不完全知识的情况下做出决定**, 这时候CWA就有用了
            - 开放世界假设(Open World Assumption, OWA)
                - 对推不出来的命题就很诚实地当作不知道这个命题的正确与否, 这样的后果就是知识库中能推导出来的结论大大减少
            - 在语义Web环境下, 因为Web的开放性, 相关的知识很可能分布在Web上不同的场所, 因此在语义Web上推理, 用CWA是很不恰当的. 例如, 如果在一个知识库中只说了hasFriend(Peter, Tom), 如果采用CWA, 就会得到结论: Peter只有一个朋友. 这当然是不合理的, 因为很可能在别的地方说了Peter还有其他的朋友. 所以, 如果要在语义Web中聚集不同来源的知识, 应该采用OWA. (有一种中庸之道: **局部封闭世界(Local Closed World)**, 这里不多说). 描述逻辑中的推理刚好是采用**OWA的, 所以它的确适合作为语义Web的逻辑基础**
        - 基于OWA的训练：
            - 样本形式：
                - 正样本集：
                - 负样本集：
            - 目标函数：
                - logistic loss最小化
                    - 优势：对一些复杂的关系模式（如transitive relations）能得到一些紧凑的表达方式
                - pairwise ranking loss最小化
                    - 优势：不假设负样本一定是(命题)错误的，只是和正样本相比可能性小，使得positive facts得分要尽可能高于negative ones
                - 以上的目标函数中均包含约束项/正则项【不同的embedding模型不同】：
                    - 已证明：logistic loss+semantic matching models（DisMult、ComplEx等）性能更好；
                    - pairwise ranking loss+translational distance models（TransE）性能更好
                - 优化方法：SGD+minibatch
                    - 初始化entity和relation embeddings后，每轮迭代，从正样本集中抽取positive facts集合，对每个positive fact依次产生一个或多个 negative facts，这些正负样本构成一个minibatch中的训练样本，经过一次minibatch，embeddings通过一个gradient step(具有恒定的或自适应的学习率)更新
                    - 负样本构建策略有很多，不做总结了
                    - 负采样对性能影响：越多越好，k=50是一个对准确率和训练时间很好的tradeoff
        - 基于CWA的训练：
            - 目标函数：
                - 最小均方误差，squared loss
                - logistic loss
                - absolute loss
            - 缺点：
                - 不适用于不完整的KG，即观测数据中有很多的missing facts
                - 已被证明，基于CWA的模型性能要比基于OWA的模型差
                - 引入大量的负样本，在模型训练时会引入扩展性问题
    - **模型的比较：**
        - 模型的性能与具体的任务和采用的数据都有关系
            - 表现力丰富的模型性能不一定会更好，往往需要大量参数，在小型/中型数据集上容易过拟合
            - 在link preidiction任务中，采用WordNet和Freebase数据集，**ANALOGY**性能最好
            - 除了在step2中引入的模型：事实（三元组）还可利用**paired formulation**进行建模：
                - 将entity pair->(h,t)表达为矢量**p**,r表达为矢量**r**，fact的合理性有两个矢量内积决定，**这种entity pair的表示经常在关系抽取中使用**
                - 将head entity h表达为**h**，（r,t）->表达为矢量**p**
                - 缺点：
                    - 未成对的实体间关系不易发现
                    - 空间复杂度增加
                    - 对于两个首尾实体对h1,t和h2,t，如果共享tail entity t,但是h1,t与 h2,t采用不同的vector representation，那么二者共享的tail entity信息就会丢**失了**
- **利用额外的信息进行KG embedding，包括 entity types, relation paths, textual descriptions, as well as logical rules，对只基于facts的KG embedding 模型进行优化**
    - 基于实体类型，即实体属于哪个语义范畴：
        - e.g. AlfredHitchcock(阿尔弗莱德·希区柯克)的type为Person，这种信息在多数KGs中都是可用的
        - 通常以特定关系编码，并以triples形式保存，e.g.（Psycho, **IsA**, CreativeWork). 即使用IsA作为普通的关系，相应的三元组作为普通的训练样本
        - SSE(semantically smooth embedding)
            - 假设：具有相同type的实体在embedding space中stay close
            - 利用 Laplacian eigenmaps和locally linear embedding构建正则化项，对embedding task进行约束
            - 缺点：认为实体的语义范畴不是非层次结构的，每个实体直属一个种类，这与真实世界中的KGs是矛盾的
        - TKRL(type-embodied knowledge representation learning)
            - 能够处理分层的实体类别和多类别标签，解决了SSE的不足
            - 是一个特定实体类型预测（type-specific projection ）的翻译距离模型（translational distance models），它对打分函数进行了优化
                - 利用type-specific projection matrices对h,t进行映射
                - 多类别标签：投影矩阵中元素表示为所有可能的type matrices的加权和
                - 分层的类别：将所有子领域的project matrices矩阵进行组合
                    - 加性组合
                    - 乘性组合
            - 缺点：尽管在一些任务中如 link prediction和triple classification性能良好，但空间复杂度相对高
        - 实体类型还能用来对不同关系中的 head and tail positions进行**类型约束**
            - e.g. 具有关系DirectorOf的head entity类型应为Person
    - 基于关系路径(relation path)，即实体间的多跳关系：
        - 包含丰富的语义线索，对KGs的补全有重要作用
        - 在多元关系数据中被广泛研究，e.g.路径排名算法：
            - 利用两实体间的路径作为特征去预测二者潜在的关系
            - 应用于KG embedding，如何将这些paths与entities和relations表示在相同的向量空间中?
                - **使用组合策略**：将path表示为组成它的关系的表示形式的组合，常用的组合策略：
                    - 加性组合
                    - 乘性组合
                    - RNN
        - PTransE(path-based TransE): TransE的扩展，
            - PTransE考虑了以上所有的组合策略（3种）
            - 与TransE相比，性能有大幅度提高
        - 文献【28】提出另一种相似的架构：
            - 构建三元组：using entity pairs connected not only with relations but also with relation paths，使用（h,p,t）p=r1->r1->r2->r3->...->rl
            - 模型是对 TransE和RESCAL的扩展：
                - 对二者的score function进行扩展:
                    - TransE中r->p,采用加性模型，r->r1+r2+...+rl
                    - RESCAL中r->p,采用乘性模型，M->M1*M2*...*Ml

        - 这种方法在answering path queries on KGs上性能很好
    - 尽管性能提升了，但是大量的paths会引入复杂度的挑战，部分文献通过对现有方法进行采样、剪枝、动态规划算法等改善存在的问题
  - 基于文本描述(textual description)，KGs中对实体简洁的描述包含了丰富的语义信息：
    - 原始模型：NTN，仅利用文本信息去初始化实体表示，**将KG facts和文本信息隔离，不能很好利用二者间的交互**
    - 文献【30】提出模型，解决了NTN中的问题：
      - 将制定KG与一个附加的文本语料对齐，将KG embedding和word embedding共同创建
      - 实体/关系与词的表示在同一矢量空间中，更有意义
      - 联合建模包含3个部分：
        - knowledge model, 使用TransE的变种
        - text model, 使用Skip-gram的变种
        - alignment model，保证实体/关系向量与词向量在同一矢量空间中，可能会利用很多机制：
          - 通过实体名称对齐
          - 通过 Wikipedia anchors对齐
          - 通过实体描述对齐
      - 联合embedding利用了KGs的结构化信息和文本的非结构化信息，能够彼此增强，此外，这两类信息的对齐能实现**KG外实体的预测**，e.g. phrases 出现在web text，但还未出现在KGs
    - DKRL(description-embodied knowledge representationlearning)
      - 也是对TransE的扩展，实验结果表面在zero-shot scenario with out-of-KG entities场景，DKRL性能优于TransE
      - 用两种矢量表达描述实体e:
        - 基于结构化的es，捕捉了KG中facts反映的结构化信息
        - 基于描述的ed，捕捉了实体描述中的文本信息
    - TEKE(text-enhanced KG embedding model)
      - 首先在语料库中注释实体，创建一个由实体和单词组成的共现网络
      - 对每个实体e,在共现网络中定义一个文本上下文n(e)作为其邻居，文本上下文的向量**n(e)**定义为在n(e)中词向量的加权平均
      - 对三元组中的每个关系r，TEKE定义了一个文本上下文作为h和t的公共邻居n(h, t) = n(h) 交集 n(t)，用与上面相似的方法得到向量**n(h, t)，A,B**为权重矩阵，更新三元组
        - **r_new = Bn(h,t)+r**
        - **h_new = An(h)+h**
        - **t_new = An(t)+t**
      - 能学到更丰富的实体/关系表达，性能胜过原始模型TransE，TransH，TransR
  - 基于逻辑规则(logical rules)，依据一阶**霍恩子句**：
    - e.g. 任意x;y : HasWife(x;y)=>HasSpouse(x;y)，任意通过关系HasWife连接的两个实体，也应该被关系HasSpouse连接
    - 逻辑规则包含丰富的背景知识，**广泛在知识获取和知识推理等方面被研究**，常基于马尔科夫逻辑网络
    - 现有的系统如 WARMR , ALEPH , 和AMIE能自动从KGs中提取逻辑规则
    - 文献【23,24】提出利用规则改善embedding模型，但是规则建模与embedding建模是隔离的，只是增加了一个后期加工个的步骤，性能提升有限
    - 文献【34，35】提出将二者同时建模，提出KALE，使得facts和rules在一个统一的框架中建模
      - 学习到的embedding不仅与facts兼容，还与rules兼容，在**知识获取和知识推理**上更有效
      - facts被当做一个 ground atom，定义其truth value
      - 逻辑规则首先需要实例化为ground rules
        - e.g. 任意x;y : HasWife(x;y)=>HasSpouse(x;y)实例化结果：任意x;y : HasWife(AlfredHitchcock;AlmaReville)=>HasSpouse(AlfredHitchcock;AlmaReville)
        - 需要执行grounding procedure，缺点是当KGs中存在大量的实体，或者它们的规则非常复杂时会很耗时耗空间
      - 实例化后，ground rules会被解释为由ground atoms和logical connectives构成的**复杂规则**，可通过 t-norm fuzzy logics 建模
    - 文献【111】作为文献【35】扩展，解决其存在问题：
      - 避免grounding，不会实例化x,y，但这种策略只适用于简单规则，**不能推广到复杂的规则**

- **利用其它信息**
  - 利用实体属性
    - KGs中的关系不仅能表示实体间的关系【对象属性】还能表示实体的属性【数据属性】
      - 但大多数KGs embedding技术并未对二者进行区分，以RESCAL为例，不区分的结果导致tensor维度大幅度增加
      - 文献【22】提出区分二者，relations仍用tensor进行编码，attributes用一个单独的entity-attribute矩阵
  - 利用时间信息
    - KGs对时间是敏感的，对模型添加时间顺序约束，比如BORNIN和DIEIN是有先后顺序的
    - time-aware embedding model
  - 利用图结构
    - graphaware embedding model
    - 利用三种图结构学习entity和relation的表达
      - neighbor context：类似KGs中的三元组
      - path context：类似之前介绍的 relation paths
      - edge context：给定一实体，其edge context定义为所有的relations连接到该实体或者从该实体引出的（入度+出度）
  - Evidence from Other Relational Learning Methods
    - 结合pathranking algorithm (PRA)
      - MLP+PRA
      - RESCAL+PRA
- **KG embedding在KG中的应用**
  - link prediction，也叫作entity prediction或者entity ranking
    - 预测一个实体是否与另一实体间存在特定的关系
      - （？，r, t）或者（h,r,?）
      - 本质上就是一个KG completion任务，添加graph中确实的knowledge
    - 类似的任务，（h,?，t）即 relation prediction
    - 在完成实体和关系的表示后，link prediction只需要在进行一个排名步骤ranking
  - triple classification
    - 用于验证一个unseen triple fact （h,r,t）是否为true
    - 在完成实体和关系的表示后，每个三元组都有一个得分，triple classification可在score的基础上进行，三元组得分越高的越可能为true fact
    - 对unseen triple fact进行预测，对score设置门限，门限以上为true，否则为false
  - entity classitication
    - 将实体划分到不同的语义范畴
    - 可以当做link prediction特例，（x, IsA，？），是一个KG completion任务
  - entity resolution:实体解析
    - 验证两个实体是否属于同一个对象
    - 文献【18】指定这样的场景：
      - KG已经包含了relation用于说明两个实体间是否是等价的，即表示为'EQUALTO', embedding也已经从relation中学到
      - 这样，实体解析退化为triple classification，即判断（x;EqualTo;y）是否保留，或有多少可能保留
      - 这种直观策略并不总能work，因为不是所有KG都会对关系'EQUALTO'进行encode
    - 文献【13】提出只在实体表达的基础上进行实体解析
- **KG embedding在非KG中的应用**
  - 关系抽取
    - 在纯文本中在实体已经被识别出之后抽取relational facts
    - 文献【20】提出将一个text-based extractor和TransE结合，可以更好的进行关系抽取

        - 【缺】
    - 问答系统【缺】
    - 推荐系统
        - 文献【133】提出一种混合的推荐架构，利用了KG中的异构信息去提升协同过滤的性能
            - user的latent vector【u_i】
            - **使用了KG中存储的三种信息**，去构建item的latent vector【e_j】
                - 包含结构化知识（triple facts）、文本知识（一本书或者电影的textual summary）、视觉知识（一本书的封面或者电影的海报图片）去导出items的语义表达
                    - 结构化知识（triple facts）：可使用典型的KG embedding技术，e.g. TransR
                    - 文本知识：使用堆叠的去噪自编码器抽取
                    - 视觉知识：使用堆叠的卷积自编码器抽取
            - user i对item j的偏好定义为两个latent vector的乘积

---

3 Deep Learning for Event-Driven Stock Prediction【利用事理图谱】

- Summary:
    - 利用DL做事件驱动的股票预测
    - 事件从新闻文本中提取，表示为特征向量，使用tensor network训练
    - 使用CNN对事件受对股票价格的短期和长期影响进行建模
- 股票价格波动受新闻或者事件影响，刻画方式：
    - 早期方法：
        - 从新闻文本中构建简单的特征：e.g.词袋，名词短语，命名实体，特征过于简单，无法捕捉结构化关系
            - e.g."微软起诉了 Barnes & Noble 公司"，如果只采用term-level 的特征，{“微软”， “起诉”， “ Barnes & Noble 公司”}，这种非结构化的词语无法区分“原告”和“被告”
        - 构建结构化特征能够提升性能：
            - 利用open information extraction（Open IE）提取结构化特征表示
            - 缺点：稀疏性增加，限制了预测的能力
        - 使用event embedding表示结构化事件：
            - 被表示为dense vector，在使用density estimator(如CNN)训练embedding时，会取得比较好的结果，但是在高位空间中会发生行为异常
            - 本文提出，采用**NTN（neural tensor network）训练**，可以针对事件变量学习其语义的组合性，通过显式乘性结合它们而非像标准神经网络中中隐形使用它们
                - 事件表示和提取：
                    - 将事件表示为4元组E(O1,P,O2,T)：，每个元素叫做事件E的变量（event argument）
                        - O1: actor
                        - P: action
                        - O2: object
                        - T:事件的时间戳，用于将新闻数据和股票数据对齐，不参加embedding的构建
                    - 使用**OpenIE和依存分析技术**从自由文本中提取结构化事件：
                        - 首先使用**ReVerb**从新闻文本中的一句话提取候选(O1’,P’,O2’)
                        - 在使用**ZPar**解析句子提取主语、谓语、宾语【假定在(O1’,P’,O2’)中包含主语、谓语、宾语，如果不包含就剔除掉该候选三元组】
                        - 大规模新闻数据的冗余性允许使用这种方法去捕捉具有高召回率的重要事件
                - 事件特征学习（event embedding）：
                    - 之前的工作：
                        - 事件本身具有稀疏性，可以使用一些补偿特征减小稀疏性（e.g.使用(O1,P)、(P,O2)、O1,P,O2）
                        - 将verbs推广到verb classes,使得相似的actions均变为一个feature
                    - 使用NTN，可以自动学习event tuple的embedding
                        - 与一些以前的工作（从知识图谱中学习多关系数据的分布式表示）相似，但这些工作并不能解决该问题，原因如下：
                            - 知识图谱中关系类型的数量是有限制的，利用矩阵/tensor对关系建模，为每种特定的关系类型训练一个模型
                                - 我们要使用OpenIE技术提取event，event type是一个开放集，很难针对每一个event type都训练一个模型
                                - 可以将P表示为vector,共享event argument的维度
                            - 关系数据库的embedding的目标是明确两个实体(e1,e2)间是否包含指定的关系R，R是对称的话，两个实体是可交换的
                                - event argument中每个变量都有特定的角色，彼此间不可交换
                                - 使用tensor T1,T2分别对O1,O2进行建模
                                - O1T1P和PT2O2进一步用于分别构建**两个角色独立的embedding R1,R2**
                                - tensor T3用于在R1,R2间进行语义组合，生成一个针对事件E(O1,P,O2,T)的完成的**结构化embedding U**
                            - **NTN的输入：word embedding,输出：event embedding**
                                - word embedding使用skip-gram从大规模财经语料中学习，本文中使用这种预训练的词向量比随机初始化的embedding效果略好
                                - 每个事件变量可能有多个单词，表示actor，action，object时采用这些词的平均word embedding
                    - 训练：
                        - 从新闻语料中提取了1000万事件（正样本）E，并构建负样本（corrupted tuples），score(正样本)>score(负样本)
                            - 负样本E_r：三元组中将O1替换为在词典D【包含训练数据中的所有词】中的任意词
                        - **使用margin loss最小化训练embedding**：loss(E,E_r)，margin loss见https://www.cnblogs.com/yymn/p/8336979.html
                        - $loss(E, E^r) = \max(0, 1 - f(E) + f(E^r)) + \lambda \|\Phi\|_2^2, \quad \Phi = (T_1, T_2, T_3, W, b)$ is the set of parameters.
                        - l(y,y')=max(0,m−y+y')
                            - y是正样本的得分，y’是负样本的得分，m是margin（自己选一个数）
                            - 希望正样本分数越高越好，负样本分数越低越好，但二者得分之差最多到m就足够了，差距增大并不会有任何奖励
                            - 是margin loss（Hinge loss） l(y)=max(0,1−t⋅y)的变种
                                - y是预测值（-1到1之间），t为目标值（±1）
                                - 分类器可以更专注整体的分类误差。
                        - 训练词向量时常用的损失函数
                - 深度预测模型：
                    - 对股价变化用三种长度的时间刻画：
                        - 长期事件，上个月的事件
                        - 中期事件，上周的事件
                        - 短期事件，昨天的事件
                    - **输入：event embedding序列（依照时序），以天为单位，输出二分类（股票涨/跌）**
                        - 长期事件，30个输入;中期事件，7个输入
                            - 进行narrow卷积操作，窗口长度为3（类似利用滑动窗口的特征提取），窗口的embedding共享相同权重
                            - 有必要利用所有局部特征，从全局预测股票波动，因此要使用MaxPooling【只保留通过卷积操作的最重要的特征】
                        - 将长期，中期，短期最终输出的特征向量结合起来，将该特征向量与股价关联==>使用带一个隐藏层和一个输出层的的前馈神经网络
                        - 对于新闻语料用于预测的效果，实验证明新闻的题目比新闻的内容更有效，因此这里仅提取了新闻的标题

---

4 Constructing Narrative Event Evolutionary Graph for Script Event Prediction【因果事理图谱构建及特征学习】

1. Summary:
    1. 构建了一个抽象因果网络，并将其嵌入到一个连续矢量空间中
    2. 为了对网络进行特征学习，设计了一个双重因果关系转换模型
    3. 可以将因果网络用于事件预测、事件聚类、股市波动预测
2. 将事件的因果关系用于downstream applications：
    1. **早期工作用于事件预测、生成future scenarios，存在的问题**：
        1. 仅针对特定事件的因果关系，无法发掘一般的因果模型
        2. 在事件预测、future scenario生成中，event matching是一个关键问题，但使用的tuple matching/phrase matching方法【符号性质，即n元组表示】很大程度的限制了匹配的灵活性，进而影响预测的准确性
        3. 因果本身是一种可用于推理、预测的重要方法，但由以上文献中生成的因果性【符号形式】很难扩展到其他应用
    2. 针对以上问题，本文：
        1. 构建抽象新闻事件因果网络，获取一般的，频繁简单的因果模式
            1. 首先使用文本的因果连接器【X because Y】，识别并提取因果关系片段（**causality metion extraction**）
            2. 从识别的关系片段中，提取特定的因果事件，获取高质量，可读的因果关系对(**c**)，每个事件【节点】表示为动词、名词集合【保序】
            3. 进一步发掘一般模式，发现高级因果规则并减少网络稀疏：
                1. 将关系对中的名词推广至其上位词【利用Wordnet】,动词推广至其所属类别【利用VerbNet】
        4.提出分层的因果关系生成法(**causal event generation**)，在特定因果网络之上构建抽象的因果网络
            1. 后者的节点为频繁共现的词对【frequently co-occurring word pairs (**FCOPA**) 】

        2. 使用embedding简化event matching，容易扩展到其他应用（**causality network embedding model**）

1. 设计了一个双重因果关系转换模型
    1. 与现存的relation embedding模型不同，首次对多对多关系建模，增强对非对称关系【事件因果关系】建模
        1. 将cause-to-effect和effect-to-cause表示为不同的**转移向量t和τ**
        2. 利用这个模型，对事件因果关系的**关键属性进行编码，包含非对称性、多对多、传递性、事件因果性**

3. causality metion extraction

1. 在非结构化的自然语言文本中识别潜在的cause-effect对【语料大，无法完全实现人类标注，实现自动识别】
    1. 设计文本的因果连接器causality connectors【e.g. X because Y】
        1. 让人类标注者对每个connector都采样100个新闻标题，判断这些标题是否表示了因果性
        2. 计算每个connector表示因果关系的频率，具有最高频率的四个connector为“because”，“because of”，“lead to”and“after”
    2. 构建规则集提取causal events mentions
        1. 规则模板 <Pattern, Constraint, Priority>
            1. **Pattern**：包含 connector的一个正则表达式s
            2. **Constraint**：对句子的句法限制
            3. Priority：表示几个规则均匹配了，规则的优先级
            4. e.g. pattern“**after [sentence1], [sentence2]**”to extract causality mentions with a constraint that **[sentence1] cannot start with a number**
    3. 经过应用上述rules，外加Stanford POS Tagger识别动词，名词，外加partial parser确定动词，名词次序，获得了 pairs of causality mentions【标注了cause和effect】

4. pairs of causality mentions

1. 从causality mentions中提取causal events
    1. 传统做法：causal events被表示为类似（主语，谓语，宾语）这样的元组或名词短语
        1. 本文采用新闻标题作为原始语料，表达形式往往很简洁，很多成分均被忽略了，很难提取上述信息
        2. 且使用上述表达方式存在很多问题，如：
            1. 新闻标题中涉及的事件很少表现为完整的主谓宾结构，很多重要信息均未被提取到
            2. 使用元组或名词短语很可能会丢失事件的重要信息
            3. 多个元组或名词短语都被提取后，很难决定哪个是最好的
            4. 使用元组或名词短语提取手段的性能很大程度依赖NLP工具【e.g. **Reverb**】
        3. 使**用有序的动词/名词集合表示事件**效果更好，解决以上问题
            1. 该方法不仅适用于新闻标题，任意文本数据均可
            2. 包含更全面信息，减少对NLP工具依赖
            3. 每个边连接一个cause-effect对，从cause到effect

5. causal event generation

1. 首先，使用WordNet和VerbNet归纳特定因果事件中出现的单词
    1. 见2.2.1.3.1，消除了单词多样性导致的负面影响
    2. 能在大量的特定因果事件中发现频繁模式
2. 设计一个分层因果关系生成方法
    1. 见2.2.1.4.1，**FCOPA**指两个单词共现超过5个特定事件的最低支持度次数
    2. 之前提到的节点是有共现词对组成，不难实现将词对扩展为3个词的集合或者4个词的集合
        1. 在本文中，将抽象节点表示为词对由于新闻标题的具体特点
3. 构建和一个抽象的因果网络的优势有3个方面：
    1. 包含丰富的一般化、频繁的、简单的因果关系模式，帮助人们更好理解特定因果事件的高级因果关系规则
    2. 抽象的比具体的更容易推广
    3. 比具体的更dense，使得接下来的embedding成为可能

6. causality network embedding model

1. 见2.2.2.1.1.2，非对称性用于区分cause和event事件，传递性用于捕捉长期事件的因果特性，多对多用于事件预测【否则只能发现一个cause或effect，这与现实是偏离的】
2. 提出Dual-CET(dual cause-effect)模型，设计能量函数**f(c,e):**
    1. **f(c,e)=||c + t−e||1 +||e + τ −c||1**,真正的因果关系对能量函数值小
    2. 为学习event embedding **x** 和转移向量 **t和τ**，定义排序准则，e.g.对应一个真的cause-effect pair，如果cause或者effect缺失，模型应能够预测出正确的event，训练目标是学习能量函数f,使得其可以成功的排序真的cause-effect pair，它在所有其他可能的pairs之后（因为它的能量函数值最小）

$$\min_{\{\mathbf{x}\},\mathbf{t},\tau} \sum_{(c,e)\in\mathcal{P}^+} \sum_{(c',e')\in\mathcal{P}^-} \left[\gamma + f(c,e) - f(c',e')\right]_+ + \frac{\alpha}{\|\mathbf{t}+\tau\|_2}$$

    3. margin loss最小化，其中P+为在抽象因果关系网络中的true case-effect，P-为corrupted pairs（负样本）通过替换cause或者effect生成
    4. 优化过程通过mini-batch模式的SGD
    5. 为防止过拟合，强制要求每个事件的embedding x,||x||=1
    6. 1800万纽约时报语料提取了1729个抽象事件3134个因果关系